



控制工程  
*Control Engineering of China*  
ISSN 1671-7848, CN 21-1476/TP

## 《控制工程》网络首发论文

题目: 端边云协同的苛性比值智能预报方法  
作者: 李玉超, 赵亮, 贾瑶, 张亚军, 柴天佑  
DOI: 10.14107/j.cnki.kzgc.20230397  
收稿日期: 2023-05-09  
网络首发日期: 2024-03-12  
引用格式: 李玉超, 赵亮, 贾瑶, 张亚军, 柴天佑. 端边云协同的苛性比值智能预报方法[J/OL]. 控制工程. <https://doi.org/10.14107/j.cnki.kzgc.20230397>



**网络首发:** 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式(包括网络呈现版式)排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

**出版确认:** 纸质期刊编辑部通过与《中国学术期刊(光盘版)》电子杂志社有限公司签约, 在《中国学术期刊(网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊(网络版)》是国家新闻出版广电总局批准的网络连续型出版物(ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

## 端边云协同的苛性比值智能预报方法

李玉超, 赵亮, 贾瑶, 张亚军, 柴天佑

(东北大学 流程工业综合自动化国家重点实验室, 辽宁 沈阳 110819)



**摘要：**溶出矿浆的苛性比值是氧化铝溶出过程表征质量、效率与消耗的运行指标，由于溶出矿浆成分频繁波动，目前使用的国外苛性比值检测仪表检测精度低，只能采用人工离线化验苛性比值，而化验结果的严重滞后导致无法实现苛性比值的自动控制，影响氧化铝产品质量。在分析氧化铝溶出过程动态特性的基础上，建立了由线性模型和未知非线性动态系统描述的苛性比值预报模型，将参数辨识与自适应深度学习相结合，提出了端边云协同的氧化铝溶出过程苛性比值智能预报方法，同时采用氧化铝生产企业的实际生产数据对所提方法进行应用验证，应用结果表明所提的智能预报方法可以实时、准确预报溶出过程苛性比值，为实现苛性比值的闭环优化控制提供条件。

**关键词：**苛性比值；自适应深度学习；端边云；长短期记忆神经网络；注意力机制

**中图分类号：**TP18

**文献标识码：**A

### Intelligent Forecasting Method of Caustic Ratio Based on End-edge-cloud Collaboration

LI Yuchao, ZHAO Liang, JIA Yao, ZHANG Yajun, CHAI Tianyou

(State Key Laboratory of Synthetical Automation for Process Industries, Northeastern University, Shenyang 110819, China)

**Abstract:** The caustic ratio of the dissolved slurry is the operating indicator characterizing the quality, efficiency and consumption in the alumina dissolution process. Due to frequent fluctuations in the composition of the dissolved slurry, the detection accuracy of the foreign caustic ratio detection instruments currently used is low, only manual off-line assay of caustic ratios can be used. However, the severe lag of the assay results leads to the inability to achieve the automatic control of the caustic ratio, which affects the quality of alumina products. Based on the analysis of the dynamic characteristics of alumina dissolution, this paper establishes a caustic ratio forecasting model described by a linear model and an unknown nonlinear dynamic system, and combining parameter identification with adaptive deep learning, an intelligent forecasting method is proposed for caustic ratio of the alumina dissolution process based on the end-edge-cloud collaboration. The application verification of the proposed method is performed on actual production data from an alumina manufacturer, and the results show that the intelligent forecasting method proposed can accurately forecast caustic ratio of the dissolution process in real time, providing conditions for achieving the closed-loop optimal control of the caustic ratio.

**Key words:** Caustic ratio; adaptive deep learning; end-edge-cloud; long-short term memory; attention mechanism

### 1 引言

工业上主要通过电解氧化铝生产铝，目前全球大多数氧化铝厂采用拜耳法提取铝土矿中的氧化

收稿日期：2023-05-09；

基金项目：国家自然科学基金委重大项目（61991404）；2020年度辽宁省科技重大专项计划（2020JH1/10100008）；国家自然科学基金项目（61991402, 61890923, 61973202, 62173170）；国家重点研发计划项目（2020YFB1713602）

作者简介：李玉超(2000-)，男，河北邯郸人，博士研究生，主要研究方向为流程工业关键指标预测方法、图像处理；赵亮(1995-)，男，山东潍坊人，博士研究生，主要研究方向为复杂工业过程关键生产指标检测方法；贾瑶(1986-)，男，辽宁鞍山人，博士，讲师，主要从事流程工业高性能智能控制、关键指标预测、智能运行控制和智能化系统等方面的科研工作；张亚军(1979-)，男，陕西宝鸡人，博士，副教授，主要从事非线性系统混合智能建模、数据驱动控制、复杂系统的大数据建模及高性能控制方法的科研工作；柴天佑(1948-)，男，甘肃兰州人，博士，教授，中国工程院院士，长期从事复杂工业过程控制、优化和综合自动化等方面的科研工作（本文通信作者，Email: tychai@mail.neu.edu.cn）。

铝<sup>[1]</sup>。拜耳法生产工序中的溶出过程在高温高压条件下通过碱和蒸汽将铝土矿中的氧化铝水合物溶解生成铝酸钠溶液，溶出过程的苛性比值为铝酸钠溶液中苛性碱与氧化铝的摩尔量之比，其过高和过低都会导致氧化铝的生产效率和质量下降：苛性比值过高会造成碱液损失，增加企业生产成本；苛性比值过低会造成反苛化现象，导致溶出矿浆中的氧化铝水解，影响氧化铝的溶出率进而降低企业收益。因此，苛性比值是表征溶出过程质量、效率和消耗的运行指标，对氧化铝生产过程具有重要意义。

目前苛性比值的在线检测方法主要有电导密度超声波法<sup>[2]</sup>、温度电导法<sup>[3]</sup>、采用神经网络<sup>[4, 5]</sup>的软测量方法和机理建模与软测量技术相结合的方法<sup>[6~8]</sup>。电导密度超声波法、温度电导法采用铝酸钠溶液的温度和电导率建立数学方程实现对苛性比值的软测量，需要求解的数学方程不仅收敛速度慢而且不易得到全局最优解，同时固定的数学模型难以满足长期对工况复杂多变的溶出过程苛性比值的测量要求；目前大多使用的测量苛性比值的神经网络不具备刻画具有时空关联特点的溶出过程的能力，而且神经网络参数固定，不能随工况变化自适应更新参数，导致检测效果不佳。

因此国内大多数氧化铝企业使用基于试剂滴定原理的人工离线化验苛性比值的方法，如电位滴定法<sup>[9]</sup>、光度滴定法<sup>[10, 11]</sup>和热滴定法<sup>[12]</sup>等，但此类检测方法利用溶液的状态变化确定滴定终点，对检

测环境有一定的要求，同时操作繁琐且自动化水平低，化验结果滞后，导致只能采取人工设定加碱流量控制。当生产条件频繁变化时，运行人员无法及时、准确地决策加碱流量控制系统的设定值，难以将苛性比值控制在工艺规定的目标范围内，影响氧化铝产品质量。

澳大利亚Precision Light and Air (PLA) 公司利用溶出矿浆电导率和温度与溶出矿浆成分在一定条件下呈某种数学关系建立数学模型对溶出矿浆苛性比值进行测量，该检测仪表不仅算法保密，而且其模型参数基于国外铝土矿确定，难以直接应用到我国氧化铝溶出过程苛性比值的在线检测。我国铝土矿成分相较于国外铝土矿波动大，同时矿浆流量、蒸汽压力和温度的频繁变化使得加碱流量控制系统的加碱流量频繁波动，溶出矿浆成分的频繁波动导致溶出矿浆电导率和温度与溶出矿浆苛性比值的数学关系发生改变，难以保证溶出矿浆苛性比值的检测精度。

本文将系统辨识与深度学习相结合，基于分析氧化铝溶出过程动态特性，建立了由线性模型和未知非线性动态系统描述的苛性比值预报模型，同时采用端边云协同方式提出了氧化铝溶出过程苛性比值智能预报方法，该方法运用山西某大型拜耳法氧化铝生产企业的实际生产数据进行了验证，实验结果验证了本文所提智能预报算法的有效性、准确性，为实现溶出过程苛性比值的闭环优化控制提供条件。

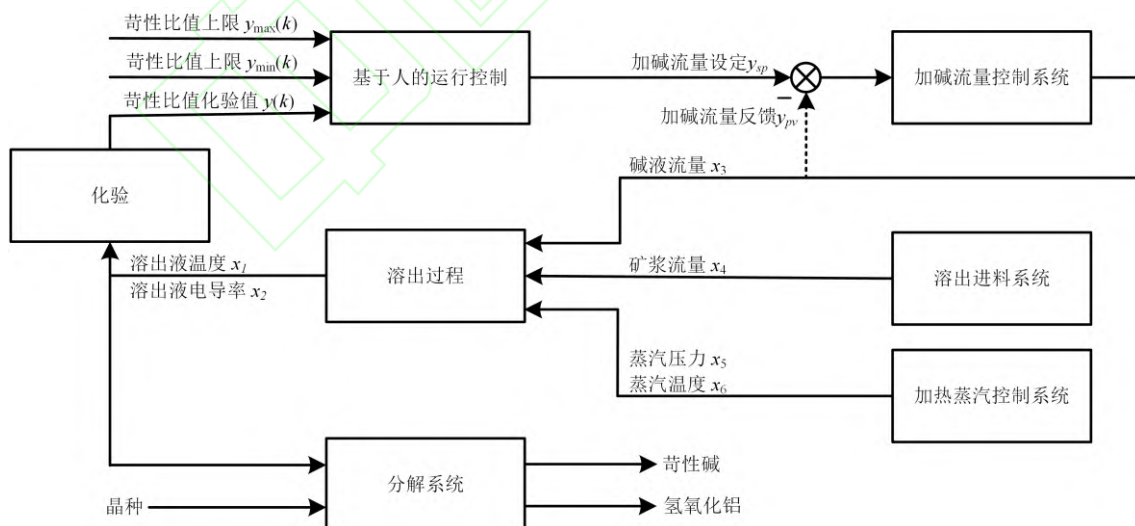


图 1 氧化铝溶出过程运行控制流程图

Fig. 1 Flowchart of alumina dissolution process operation control

## 2 氧化铝溶出过程运行控制现状分析与苛性比值预报问题描述

溶出矿浆苛性比值的定义为铝酸钠溶液中苛

性碱与氧化铝的摩尔量之比，其计算公式为：

$$\alpha_k = 1.645 N_k / A \quad (1)$$

式中， $\alpha_k$  代表溶出矿浆苛性比值，1.645 代表  $Al_2O_3$

和  $Na_2O$  的分子量的比值,  $N_k$  代表铝酸钠溶液中苛性碱的浓度,  $A$  代表铝酸钠溶液中的氧化铝的浓度。氧化铝溶出过程运行控制流程图如图 1 所示。溶出进料系统将铝土矿、石灰与苛性碱溶液混合产生矿浆, 矿浆在加热蒸汽控制系统提供的高温高压的条件下产生溶出矿浆。为了保证溶出矿浆的苛性比值在目标范围内, 加碱流量控制系统的运行人员根据苛性比值的目标范围  $[y_{\min}(k), y_{\max}(k)]$  与苛性比值化验值调整加碱流量控制系统的设定值, 通过控制系统使被控过程的输出跟踪设定值, 将溶出矿浆苛性比值控制在目标区间。

氧化铝溶出过程加碱流量、矿浆流量、加热蒸汽的压力和温度等多种因素的影响导致溶出矿浆成分频繁波动, 造成现场所用的国外苛性比值检测仪表存在大的检测误差, 无法用于溶出过程苛性比值的运行控制, 只能依靠人工化验获得准确的苛性比值, 而其化验结果严重滞后, 导致运行人员无法及时、准确地决策加碱流量控制系统加碱流量的设定值, 难以将苛性比值控制在目标范围内, 从而影响氧化铝产品质量。

### 3 氧化铝溶出过程苛性比值智能预报模型

氧化铝溶出过程苛性比值运行控制流程图如图 2 所示, 操作员根据溶出矿浆温度、溶出矿浆电导率以及苛性比值目标区间和化验值决策加碱流量设定值, 在加碱流量闭环控制系统作用下跟踪其设定值, 从而将苛性比值控制在目标区间。



图 2 苛性比值运行控制流程图

Fig. 2 Flow chart of manual alkali flow control

当溶出时间一定时, 溶出速度越快消耗的苛性碱越多, 溶出矿浆的苛性比值就越低, 提高溶出温度可以加快溶出速度。在稳定运行情况下, 溶出矿浆温度与溶出矿浆苛性比值的的关系如表 1 所示<sup>[13]</sup>。

表 1 溶出矿浆温度与苛性比值的的关系

Tab. 1 Relationship between the temperature and the caustic ratio of the dissolved slurry

溶出矿浆温度(°C)	260	270	290	310	320
苛性比值	1.50	1.45	1.30	1.25	1.20

溶液中的酸、碱、盐或带电胶体可以迁移电荷,

因此溶液的导电能力与溶液的成分存在较强的相关性, 同时温度对溶液电导率的作用明显<sup>[14]</sup>, 温度升高使得溶液粘度降低, 溶液中的粒子的移动速度增大, 使得溶液的电导率升高。如图 3 所示, 氧化铝浓度  $c_a$ 、苛性碱浓度  $c_k$ 、碳酸碱浓度  $c_c$  在不同组分浓度下, 溶出矿浆温度  $T$  与电导率  $d$  的关系近似为线性关系<sup>[15]</sup>。




图 3 溶出矿浆温度与电导率之间的关系

Fig. 3 Relationship between the temperature and conductivity of the dissolved slurry

溶出过程中加热矿浆流量、加热蒸汽压力、加热蒸汽温度通过影响溶出过程的反应速度影响苛性碱的消耗从而对溶出矿浆的苛性比值造成影响。

通过苛性比值运行控制过程分析和溶出过程机理分析, 溶出矿浆温度、溶出矿浆电导率、加碱流量、矿浆流量、加热蒸汽压力、加热蒸汽温度是影响苛性比值的重要因素, 因此可以将溶出矿浆苛性比值描述为

$$\alpha k = g(T_{\text{slurry}}, d, f_{\alpha k}, f_{\text{slurry}}, F, T_{\text{steam}}) \quad (2)$$

其中,  $\alpha k$  为苛性比值,  $T_{\text{slurry}}$  为溶出矿浆温度,  $d$  为溶出矿浆电导率,  $f_{\alpha k}$  为加碱流量,  $f_{\text{slurry}}$  为矿浆流量,  $F$  为加热蒸汽压力,  $T_{\text{steam}}$  为加热蒸汽温度,  $g(\cdot)$  为上述影响因素与苛性比值  $\alpha k$  的非线性函数。

在基于规则推理的苛性比值人工运行控制作用下, 溶出矿浆苛性比值在目标区间附近波动, 因此溶出矿浆苛性比值可以用线性模型和未知非线性动态系统描述。采用溶出矿浆温度  $x_1(k)$ 、溶出矿浆电导率  $x_2(k)$ 、加碱流量  $x_3(k)$  为输入, 溶出矿浆苛性比值  $\bar{y}(k)$  为输出的线性模型。线性模型中的未知参数需要进行辨识, 存在建模误差, 同时线性模型没有考虑其他因素的影响, 因此建立未知非线性动态模型  $v(k)$  作为线性模型的补偿模型, 从而可将溶出矿浆苛性比值的输出  $y(k)$  表示为



$$y(k) = \bar{y}(k) + v(k) \quad (3)$$

式中,  $\bar{y}(k)$  和  $v(k)$  分别为

$$\begin{aligned} \bar{y}(k) &= ax_1(k) + bx_2(k) + cx_3(k) + d \\ &= \mathbf{x}(k)\boldsymbol{\theta} \end{aligned} \quad (4)$$

式中,  $\mathbf{x}(k) = [x_1(k), x_2(k), x_3(k), 1] \in \mathbb{R}^{1 \times 4}$ ,  $d$  为常数项,  $\boldsymbol{\theta} = [a, b, c, d]^T$ 。

$$\begin{aligned} v(k) &= f(x_1(k), \dots, x_1(k-n+1), x_2(k), \dots, \\ &\quad x_2(k-n+1), \dots, x_6(k), \dots, x_6(k-n+1)) \end{aligned} \quad (5)$$

式中,  $f(\cdot)$  为未知非线性函数,  $x_4(k)$  为矿浆流量,  $x_5(k)$  为加热蒸汽压力,  $x_6(k)$  为加热蒸汽温度,  $n$  为非线性动态系统输入变量的阶次,  $n$  为常数,  $k$  为变量。

由式(3)和式(4)建立参数  $\boldsymbol{\theta}$  的辨识方程

$$y(k) = \mathbf{x}(k)\boldsymbol{\theta} + v(k), k = 1 \dots m \quad (6)$$

其中,  $m$  表示采集到  $m$  个时刻的  $x_1(k) \sim x_6(k)$  以及苛性比值化值  $y(k)$  的数据量。

把式(6)表示成向量的形式

$$\mathbf{Y}(k) = \mathbf{X}(k)\boldsymbol{\theta} + \mathbf{V}(k) \quad (7)$$

式中, 输出向量  $\mathbf{Y}(k)$  为

$$\mathbf{Y}(k) = [y(k), y(k-1), \dots, y(k-m+1)]^T \in \mathbb{R}^{m \times 1} \quad (8)$$

输入矩阵为  $\mathbf{X}(k)$  为

$$\begin{aligned} \mathbf{X}(k) &= \begin{bmatrix} x_1(k) & x_2(k) & x_3(k) & 1 \\ x_1(k-1) & x_2(k-1) & x_3(k-1) & 1 \\ \vdots & \vdots & \vdots & \vdots \\ x_1(k-m+1) & x_2(k-m+1) & x_3(k-m+1) & 1 \end{bmatrix} \\ &= \begin{bmatrix} \mathbf{x}(k) \\ \mathbf{x}(k-1) \\ \vdots \\ \mathbf{x}(k-m+1) \end{bmatrix} \in \mathbb{R}^{m \times 4} \end{aligned} \quad (9)$$

未知非线性项的向量  $\mathbf{V}(k)$  为

$$\mathbf{V}(k) = [v(k), v(k-1), \dots, v(k-m+1)]^T \in \mathbb{R}^{m \times 1} \quad (10)$$

式中,  $m$  为参数估计所采用的输入向量的阶次。

为了辨识参数向量  $\boldsymbol{\theta}$ , 引入最小二乘目标函数

$$J = \min[\mathbf{Y}(k) - \mathbf{X}(k)\hat{\boldsymbol{\theta}}]^T [\mathbf{Y}(k) - \mathbf{X}(k)\hat{\boldsymbol{\theta}}] \quad (11)$$

模型参数  $\boldsymbol{\theta}$  的估计值  $\hat{\boldsymbol{\theta}}$  为

$$\hat{\boldsymbol{\theta}} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y} \quad (12)$$

由式(6)可知, 氧化铝生产过程苛性比值的动态模型(3)可等价地表示为

$$\begin{aligned} y(k) &= \mathbf{x}(k)\hat{\boldsymbol{\theta}} + \mathbf{x}(k)(\boldsymbol{\theta} - \hat{\boldsymbol{\theta}}) + v(k) \\ &= \hat{y}(k) + \bar{v}(k) \end{aligned} \quad (13)$$

式中,  $\hat{y}(k) \triangleq \mathbf{x}(k)\hat{\boldsymbol{\theta}}$ ,  $\hat{y}(k)$  表示  $\bar{y}(k)$  的估计值,  $\bar{v}(k)$

是由模型式(4)输出  $\bar{y}(k)$  的估计误差和  $v(k)$  组成的未知非线性动态系统

$$\bar{v}(k) = \mathbf{x}(k)(\boldsymbol{\theta} - \hat{\boldsymbol{\theta}}) + v(k) \quad (14)$$

式中,  $\bar{v}(k)$  是模型结构、阶次与模型参数未知的非线性动态系统。

## 4 氧化铝溶出过程苛性比值智能预报方法

### 4.1 苛性比值智能预报策略

本文在分析溶出矿浆苛性比值动态特性的基础上, 将系统辨识方法与深度学习结合<sup>[16, 17]</sup>提出了如图4所示的端边云协同的氧化铝溶出过程苛性比值智能预报方法。氧化铝溶出过程  $x_1(k) \sim x_6(k)$  和  $y(k)$  的大数据可测, 其中端侧运行控制系统实时采集  $x_1(k)$ 、 $x_2(k)$ 、 $x_3(k)$ 、 $x_4(k)$ 、 $x_5(k)$ 、 $x_6(k)$ 、 $y(k)$ , 并将数据传至云侧数据服务器。边侧利用工业服务器的边缘控制系统, 执行苛性比值在线智能预报模型, 由  $[x_1(k), x_2(k), x_3(k), 1]\hat{\boldsymbol{\theta}}$  得到  $\hat{y}(k)$ , 由在线深度学习模型得到  $\hat{v}_1(k)$ , 从而由  $(\hat{y}(k) + \hat{v}_1(k))$  得到  $\hat{y}(k)$  实时预报苛性比值, 其中在线深度学习模型结构与自校正深度学习模型结构相同, 模型参数通过自校正机制从云侧服务器获取, 模型不进行训练。云侧数据服务器执行数据处理与数据存储, 人工智能计算平台执行苛性比值自校正深度学习模型与自校正机制。自校正深度学习模型采用当前时刻以及历史所有时刻下的输入输出数据, 实时更新深度学习模型的权值、偏置参数。该自校正机制实时监控在线深度学习模型的预报精度, 在精度要求不满足时, 使用自校正深度学习模型的参数校正在线深度学习模型的参数, 从而确保苛性比值的预报精度。

其中运行控制系统、基于工业服务器的边缘控制系统、数据服务器、人工智能计算平台之间的数据通过有线光缆进行传输。

### 4.2 $\bar{v}(k)$ 的自适应深度学习预报算法

氧化铝溶出过程苛性比值的动态特性受到加碱流量控制系统、溶出进料系统、加热蒸汽控制系统的影响, 导致未知非线性动态系统  $\bar{v}(k)$  的模型结构和参数不断变化, 此外, 该系统的输入、输出数据处于开放的、变化的的信息空间, 导致使用传统的完备信息空间的深度神经网络和长短周期记忆(Long short-term memory, LSTM)深度学习变得困难, 然而可以获得苛性比值动态模型的输入输出大数据, 构建由在线深度学习模型、自校正深度学习模型以及自校正机制构成的  $\bar{v}(k)$  的自适应深度学习预报算法, 其中模型结构相同的在线深度学习

习模型与自校正深度学习均采用基于 LSTM-Attention 的网络架构<sup>[18, 19]</sup>，通过注意力机制突出关键历史时刻数据的影响，并增加随机失活层<sup>[20, 21]</sup>预防模型训练过程中的过拟合现象。基于溶出过程动态系统的特性，采用未知非线性动态系统  $\bar{v}(k)$  的输入变量作为单个神经元的输入，阶次  $n$  作

为神经元的个数， $\bar{h}$  作为单个神经元节点数， $L$  作为 LSTM 层数，采用输入、输出大数据离线训练确定上述网络的  $n, \bar{h}, L$ 。采用当前时刻以及历史所有时刻的输入输出数据更新自校正深度学习模型的权值、偏置参数，采用自校正机制校正在线深度学习模型的参数来保证预报精度<sup>[22~24]</sup>。

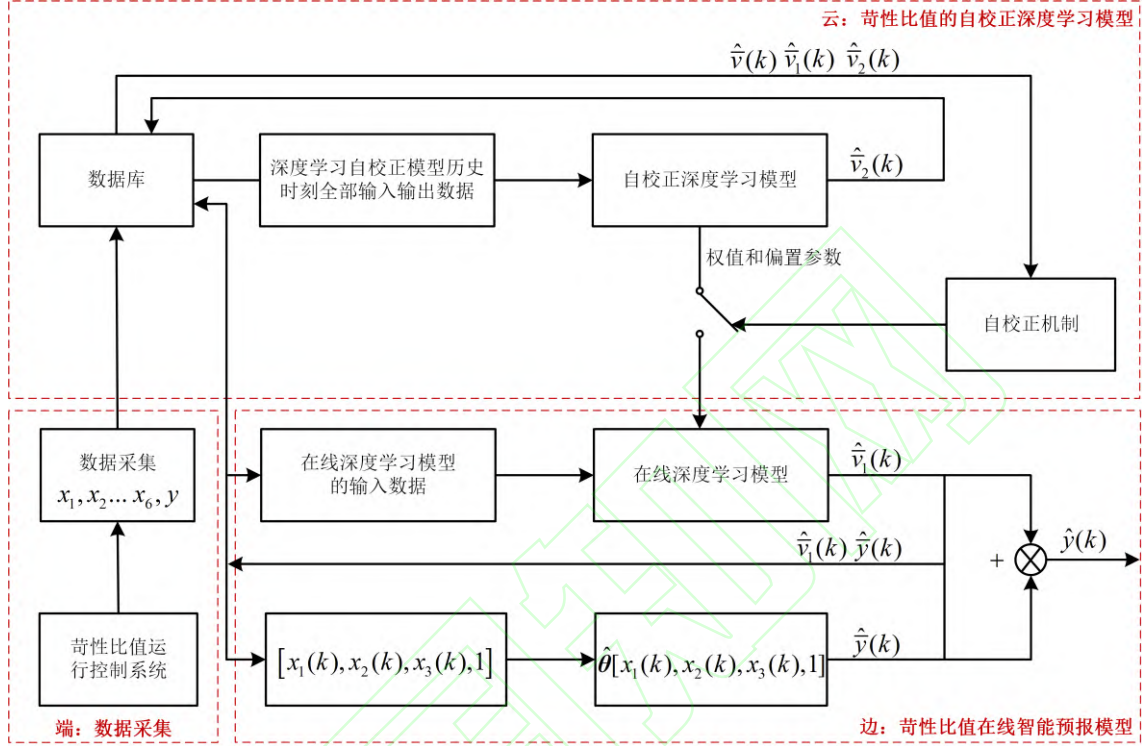


图4 端边云协同的苛性比值智能预报架构

Fig. 4 Intelligent caustic ratio forecasting architecture for end-edge-cloud collaboration

#### 4.2.1 离线确定深度学习模型结构

基于 LSTM-Attention 的深度学习模型结构如图5所示，采用如下训练方法确定该深度学习模型的  $n, \bar{h}, L$ 。以式(5)中的输入变量作为深度学习模型的输入，系统阶次  $n$  作为神经元个数，第  $j$  个神经元的输入为

$$\mathbf{x}(k+j-n) = [x_1(k+j-n), x_2(k+j-n), \dots, x_6(k+j-n)], j=1, \dots, n \quad (15)$$

深度学习模型训练的标签为化验值  $y(k)$  与线性模型输出值  $\hat{y}(k)$  的误差

$$\bar{v}(k) = y(k) - \hat{y}(k) \quad (16)$$

利用式(15)和式(16)所示的输入输出变量所构成的大数据样本，采用使标签数据  $\bar{v}(k)$  与深度学习模型输出  $\hat{v}(k)$  误差最小的训练算法，确定神经元个数  $n$ 、单个神经元节点数  $\bar{h}$ 、网络层数  $L$ 。训练的目标函数  $\mathcal{L}$  为

$$\mathcal{L}(\bar{v}, \hat{v}) = \frac{\sum_{k=1}^m \|\bar{v}(k) - \hat{v}(k)\|_1}{m} \quad (17)$$

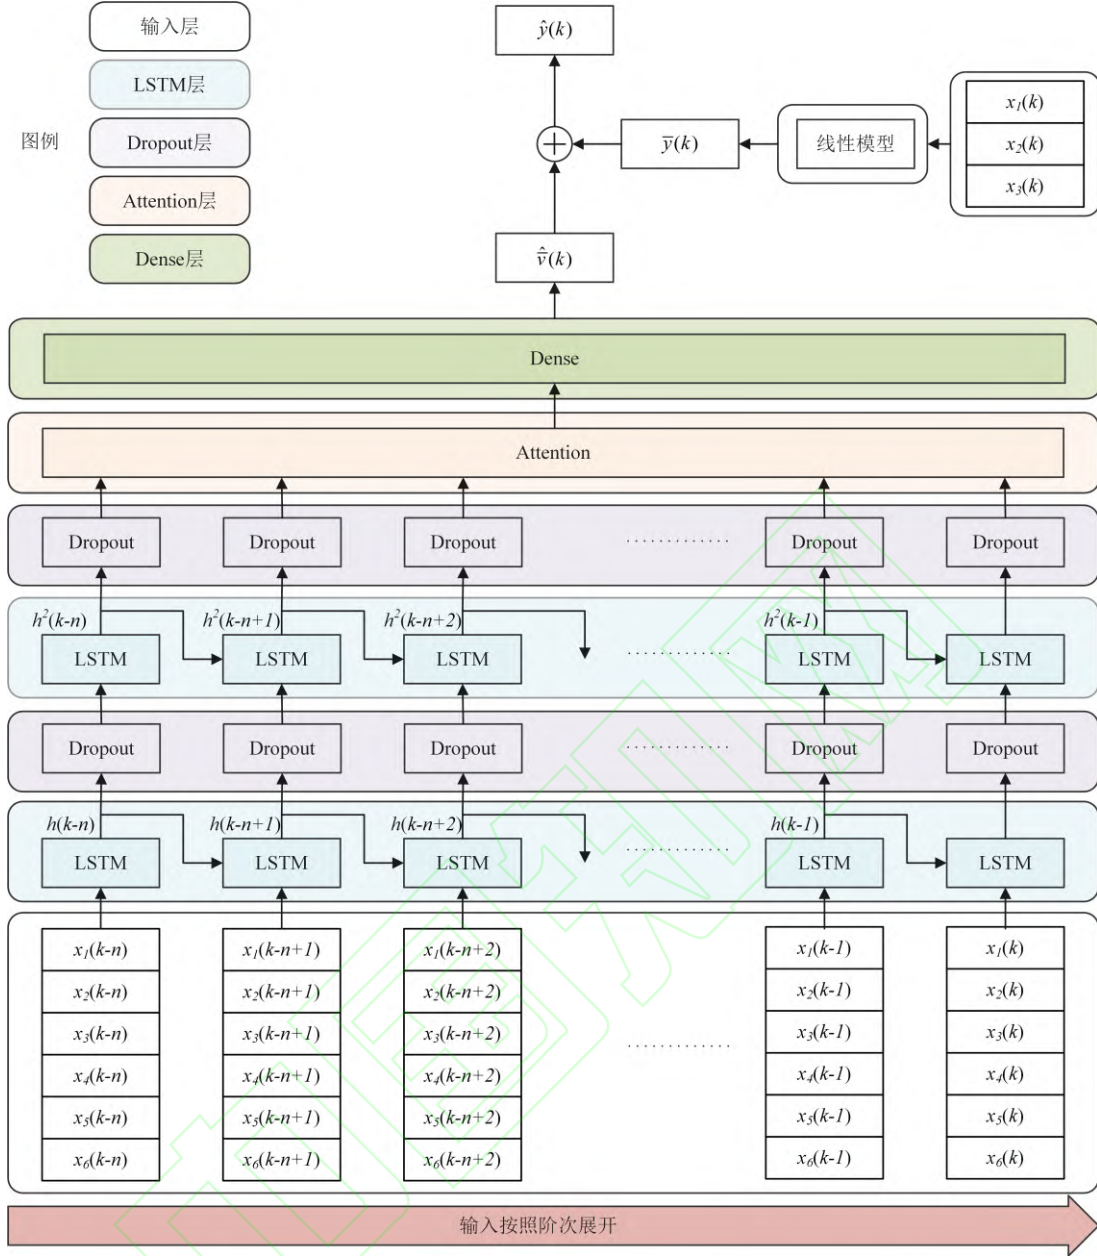
深度学习模型的输出  $\hat{v}(k)$  为

$$\hat{v}(k) = \mathbf{W}_d \boldsymbol{\alpha}(k) + b_d \quad (18)$$

式中，权值参数  $\mathbf{W}_d \in \mathbb{R}^{1 \times \bar{h}}$ ， $\boldsymbol{\alpha}(k) \in \mathbb{R}^{\bar{h} \times 1}$ ， $b_d$  为偏置参数， $\boldsymbol{\alpha}(k)$  的计算公式为

$$\boldsymbol{\alpha}(k) = \tanh([\mathbf{h}(k); \mathbf{C}_i(k)] \mathbf{W}_c) \quad (19)$$

式中， $\mathbf{h}(k), \mathbf{C}_i(k) \in \mathbb{R}^{\bar{h} \times 1}$ ， $\mathbf{h}(k)$  为 LSTM 第  $n$  个神经元的输出， $\mathbf{C}_i(k)$  为通过注意力机制得到的上下文向量， $\mathbf{W}_c \in \mathbb{R}^{2 \times 1}$  为第  $n$  个神经元输出与上下文向量的权重向量， $\tanh(\cdot)$  为双正切函数。

图 5  $\hat{v}(k)$  深度学习模型结构Fig. 5 Deep learning model structure of  $\hat{v}(k)$ 

$h(k)$  的计算公式为

$$h(k) = o_k \odot \tanh(C(k)) \quad (20)$$

式中,  $o(k) \in \mathbb{R}^{\bar{h} \times 1}$ ,  $C(k)$  为 LSTM 单元长期记忆状态,  $\odot$  为哈达玛积,  $\tanh(\cdot)$  为双正切函数, 其计算公式为

$$\tanh(c_i(k)) = \frac{\sinh(c_i(k))}{\cosh(c_i(k))} \quad (21)$$

式中,  $c_i(k)$  为  $C(k)$  的第  $i$  个元素,  $i \in [1, \dots, \bar{h}]$ 。  $o_k$  的计算公式为

$$o_k = \sigma(W_o[h(k-1), x(k)]^T + b_o) \quad (22)$$

式中,  $x(k)$  为当前的 LSTM 输入,  $W_o \in \mathbb{R}^{\bar{h} \times (\bar{h}+6)}$ ,  $b_o \in \mathbb{R}^{\bar{h} \times 1}$ ,  $\sigma(\cdot)$  为 Sigmoid 激活函数, 其计算公式为

$$\sigma(z) = (1 + e^{-z})^{-1} \quad (23)$$

式中  $z$  为自变量。

长期记忆状态  $C(k)$  的计算方式为

$$C(k) = f_k \odot C(k-1) + i_k \odot \bar{C}_k \quad (24)$$

式中,  $f_k, i_k, \bar{C}_k \in \mathbb{R}^{\bar{h} \times 1}$ , 其计算公式为



$$\begin{aligned} f_k &= \sigma(W_f[h(k-1), x(k)]^T + b_f) \\ i_k &= \sigma(W_i[h(k-1), x(k)]^T + b_i) \\ \bar{C}_k &= \tanh(W_c[h(k-1), x(k)]^T + b_c) \end{aligned} \quad (25)$$

式中, LSTM 单元权值参数  $W_f, W_i, W_c \in \mathbb{R}^{\bar{h} \times (\bar{h}+6)}$ , 偏置参数  $b_f, b_i, b_c \in \mathbb{R}^{\bar{h} \times 1}$ 。

$C_i(k)$  的计算公式为

$$C_i(k) = \sum_{j=1}^{n-1} \alpha(k+j-n) h(k+j-n) \quad (26)$$

式中,  $h(k+j-n)$  为第  $j$  个神经元的输出,  $\alpha(k+j-n)$  为第  $j$  个神经元的输出对应的权重, 其中  $\alpha(k+j-n)$  的计算公式为

$$\alpha(k+j-n) = \frac{e^{h(k+j-n)h(k)}}{\sum_{i=1}^{n-1} e^{h(k+i-n)h(k)}}, (j=1, \dots, n-1) \quad (27)$$

由式(26)和式(27)可知, 注意力向量与历史时刻的 LSTM 输出有关。采用梯度下降算法训练权值参数与偏置参数<sup>[25]</sup>, 其中权值参数  $W_d$  的训练算法为

$$W_d(i) = W_d(i-1) - \eta \frac{\partial \mathcal{L}}{\partial W_d(i-1)} \quad (28)$$

偏置参数  $b_d$  的训练算法为

$$b_d(i) = b_d(i-1) - \eta \frac{\partial \mathcal{L}}{\partial b_d(i-1)} \quad (29)$$

式中,  $\eta$  为参数训练的学习率,  $i=1, 2, \dots, n$  为模型训练过程中的迭代次数, 其他参数采用相同的训练算法确定。


深度学习模型结构  $n, \bar{h}, L$  的确定采用均方差误差 (Root mean squared error, RMSE) 指标, 在不同的网络结构下, RMSE 越小说明此网络结构下预测值与标签的偏差越小, 网络结构越接近局部最优的神经网络结构, 其中 RMSE 的计算公式为

$$RMSE = \sqrt{\frac{1}{m} \sum_{i=1}^m (\bar{v}(i) - \hat{v}(i))^2} \quad (30)$$

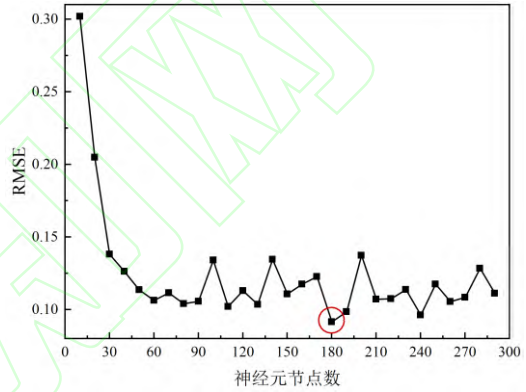
式中,  $m$  表示验证集的数据量,  $i$  代表时刻,  $\bar{v}(i)$  为苛性比值化验值与线性预报模型输出的偏差值,  $\hat{v}(i)$  为未知非线性动态系统深度学习模型的输出。

下面是确定网络结构过程<sup>[26]</sup>。首先设置 LSTM 层数为 1, 全连接层层数设置为 1, LSTM 包含的隐藏层节点数设置 100, 使神经元个数  $n$  在 10, 20, ..., 300 遍历, 使用式(15)~式(29)采用的梯度下降算法确定使得式(30)最小的  $n$ 。在确定  $n$  后, 使单个神经元节点数  $\bar{h}$  在 10, 20, ..., 300 遍历, 同样使用式(15)~式(29)采用的梯度下降算法选择使得式(30)最小的  $\bar{h}$ , 使用相同的算法再确定 LSTM 层数  $L$ 。

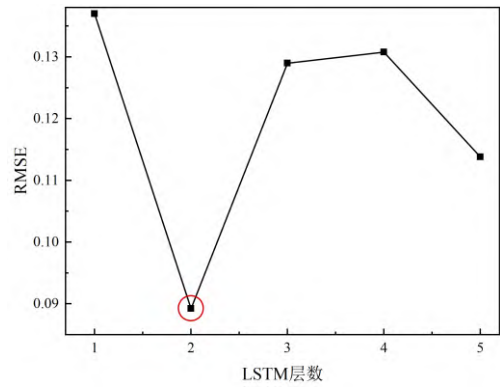
由图 6 可知, 在此算法下确定的深度学习模型为: LSTM 神经元个数为 180, 单个神经元节点数为 180, LSTM 层数为 2。



(a) 验证误差 RMSE 与  $n$  的曲线  
(a) Curve of validation RMSE and  $n$



(b) 验证误差 RMSE 与  $\bar{h}$  的曲线  
(b) Curve of validation RMSE and  $\bar{h}$



(c) 验证误差 RMSE 与  $L$  的曲线  
(c) Curve of validation RMSE and  $L$

图 6 验证误差 RMSE 与  $n, \bar{h}, L$  的关系曲线  
Fig. 6 Curve of validation RMSE and  $n, \bar{h}, L$

#### 4.2.2 在线深度学习模型

为了在线实时预报苛性比值, 在工业现场计算机部署在线智能预报模型对苛性比值进行预报, 其中在线深度学习模型不进行训练, 当在线智能预报模型精度不满足工艺要求时, 云侧的自校正机制将



校正在线深度学习模型的权值参数和偏置参数。

#### 4.2.3 自校正机制

为了将苛性比值的预报精度控制在工艺要求的目标范围内,提出自校正机制在线监控在线深度学习模型的预报精度,当在线智能预报模型不满足精度要求时,采用自校正深度学习模型参数校正在线深度学习模型对应的权值、偏置参数,从而保证在线智能预报模型的预报精度。

氧化铝溶出过程生产工艺要求苛性比值测量精度上界为  $\delta$ , 即苛性比值预报值  $\hat{y}(k)$  与化验值  $y(k)$  的精度范围为

$$|y(k) - \hat{y}(k)| < \delta \quad (31)$$

于是由式(13)以及式(31)可知

$$\begin{aligned} |y(k) - \hat{y}(k)| &= |(y(k) - \hat{v}(k)) - (\hat{y}(k) - \hat{v}(k))| \\ &= |\bar{v}(k) - \hat{v}(k)| < \delta \end{aligned} \quad (32)$$

定义在线深度学习模型预报误差  $\Delta \bar{v}_1(k)$  与自校正深度学习预报误差  $\Delta \bar{v}_2(k)$  分别为

$$\Delta \bar{v}_1(k) = |\bar{v}(k) - \hat{v}_1(k)| \quad (33)$$

$$\Delta \bar{v}_2(k) = |\bar{v}(k) - \hat{v}_2(k)| \quad (34)$$

当  $\Delta \bar{v}_1(k) \geq \delta$  且  $\Delta \bar{v}_2(k) < \delta$  时,采用自校正深度学习模型参数校正在线深度学习模型对应的权值参数和偏置参数,其他情况下在线深度学习模型参数保持不变。

#### 4.3 端边云协同的苛性比值智能预报算法

采用端边云协同的方法实现苛性比值智能预报算法:

① 端-运行控制系统实时采集氧化铝溶出过程溶出矿浆电导率  $x_1(k)$ 、溶出矿浆温度  $x_2(k)$ 、加碱流量  $x_3(k)$ 、矿浆流量  $x_4(k)$ 、加热蒸汽压力  $x_5(k)$ 、加热蒸汽温度  $x_6(k)$  和苛性比值化验值  $y(k)$ , 并将数据存储至云侧的数据服务器。

② 边-基于工业服务器的边缘控制系统执行苛性比值在线智能预报模型。由  $\mathbf{x}(k)\hat{\theta}$  计算线性模型输出  $\hat{y}(k)$ , 由在线深度学习模型得到其预报值  $\hat{v}_1(k)$ , 从而得到预报结果  $\hat{y}(k)$  实时预报苛性比值, 其中在线深度学习模型结构与自校正深度学习模型结构相同, 模型参数通过自校正机制从云侧数据服务器获取, 在线深度学习模型不进行训练。

③ 云-数据服务器和人工智能计算平台执行数据处理、数据存储、自校正深度学习模型与自校正

机制。采用当前时刻以及历史所有时刻的输入输出数据由自校正深度学习模型得出其预报值  $\hat{v}_2(k)$ ; 采用自校正机制判断式(33)所示的指标, 当在线智能预报模型的预报指标超过精度上界  $\delta$  时, 采用自校正深度学习模型的权值参数和偏置参数校正在线深度学习预报模型对应的权值参数和偏置参数。

#### 5 苛性比值智能预报算法实验

苛性比值智能预报方法的实验采用山西某氧化铝生产企业的实际生产过程数据, 其中实验数据来源工业现场的运行控制系统和检测装置, 实验前首先对数据进行了时序对齐、缺失值处理、滤波等工作完成了对数据的清洗工作。

采用 4791 组离线数据和式(12)所示的系统辨识方法得到苛性比值线性模型参数估计值

$$\hat{\theta} = [-0.013, 0.010, -0.0003, 1.836]^T \quad (35)$$

根据工艺要求, 本文提出合格率指标对所提方法预报能力进行评价, 其中合格率指标是指准确预报的样本数量占总测试样本数量的百分比。当预报结果与化验值结果误差处于  $\pm 0.025$  以内 ( $|P| < 1.8\%$ ), 将预报视为准确预报, 其中  $|P|$  的计算公式如(36)所示; 使用均方根误差指标对所提方法的预报能力进行评价, 均方根误差反映的是预报值与化验值的偏差, 可以有效地评价预报能力, 其公式如(37)所示。

$$|P| = \frac{|y(k) - \hat{y}(k)|}{y(k)} \times 100\% \quad (36)$$

$$RMSE = \sqrt{\frac{1}{N} \sum_{k=1}^N (y(k) - \hat{y}(k))^2} \quad (37)$$

式中,  $y(k)$  为化验值,  $\hat{y}(k)$  为预测值。

采用上升趋势准确率 (True positive rate, TPR) 和下降趋势准确率 (True negative rate, TNR) 评价模型的动态预报性能, 其公式为

$$TPR(k) = \frac{\sum_{i=1}^k TP(i)}{\sum_{i=1}^k TP(i) + \sum_{i=1}^k FP(i)} \quad (38)$$

$$TNR(k) = \frac{\sum_{i=1}^k TN(i)}{\sum_{i=1}^k TN(i) + \sum_{i=1}^k FN(i)} \quad (39)$$

式中的  $TP$ 、 $FP$ 、 $TN$ 、 $FN$  的计算方式为

表 2  $TP$ 、 $FP$ 、 $TN$ 、 $TN$  的计算方式  
Tab. 2 Formula of  $TP$ 、 $FP$ 、 $TN$ 、 $TN$

条件	$y(k) - y(k-1) \geq 0$	$y(k) - y(k-1) < 0$
$\hat{y}(k) - \hat{y}(k-1) \geq 0$	$TP(k)=1$	$FN(k)=1$
$\hat{y}(k) - \hat{y}(k-1) < 0$	$FP(k)=1$	$TN(k)=1$

表中  $y(k)$  为化验值， $\hat{y}(k)$  为预测值。




图 7 端边云协同的苛性比值在线预报结果  
Fig. 7 Online forecasting results of caustic ratio based on end-edge-cloud collaboration

采用端边云协同的氧化铝溶出过程苛性比值智能预报方法进行了实验，采用 9000 组输入输出数据进行在线预报，本文所提方法的预报结果与化验值的对比曲线如图 7 所示，图中五处黑色箭头处为发生自校正的时刻，将自校正深度学习模型参数下传至在线深度学习模型校正对应的权值、偏置参数。

表 3 端边云协同的苛性比值在线预报指标  
Tab. 3 Online forecasting indicators of caustic ratio based on end-edge-cloud collaboration

	RMSE	合格率(%)	TPR(%)	TNR(%)
基于端边云协同的智能预报方法	0.00901	99.31	78.92	81.65

使用均方根误差、合格率以及上升趋势准确率和下降趋势准确率指标对端边云协同的氧化铝溶出过程苛性比值在线智能预报结果进行评价，评价结果如表 3 所示，其中预报合格率达到 99.31%，结果表明本文所提智能预报方法可以在线准确预报氧化铝溶出过程苛性比值。

## 6 结论

本文利用氧化铝溶出过程苛性比值运行控制过程的特点，建立了线性模型和未知非线性动态系统组成的苛性比值预报模型，提出了由在线深度学

习模型、自校正深度学习模型、自校正机制组成的未知非线性动态系统的智能预报方法，同时采用端边云协同方式提出了由苛性比值在线智能预报模型和自校正深度学习模型组成的智能预报方法。采用山西某氧化铝企业的实时生产数据对溶出过程苛性比值进行在线预报实验，结果表明所提方法能够实现对溶出过程苛性比值的在线高精度预报，为实现氧化铝溶出过程苛性比值的闭环运行优化控制创造了条件。

## 参考文献(References)

- [1] PASTOR M A S, BOTELHO JUNIOR A B, ESPINOSA D C R, et al. Application of advanced oxidation process using ozonation assisted with hydrogen peroxide for organic compounds removal from Bayer liquor[J]. *Ozone: Science & Engineering*, 2022, 44(3): 291-301.
- [2] WELLINGTON M, VALCIN F. Impact of Bayer process liquor impurities on causticization[J]. *Industrial & engineering chemistry research*, 2007, 46(15): 5094-5099.
- [3] WEI S, XIE Y F, WANG X L, et al. An integrated model for caustic ratio prediction in the alumina digestion process[C]. *Piscataway: Proceedings of 2016 Chinese Control and Decision Conference (CCDC)*, 2016.
- [4] BROWNE G R, FINN C W P. Determination of aluminum content of bayer liquors by electrical conductivity measurement[J]. *Metallurgical Transactions B*, 1977, 8(1): 349-349.
- [5] CHEN Y R, CUI S H, CHEN P Y, et al. An LSTM-based neural network method of particulate pollution forecast in China[J]. *Environmental Research Letters*, 2021, 16(4): 044006.
- [6] HOSSAIN M S, MOHAMMAD S, HISHAM M. Short-term photovoltaic power forecasting using an LSTM neural network and synthetic weather forecast[J]. *IEEE Access*, 2020, 8: 172524-172533.
- [7] XIE S, WANG H Z, PENG J C. A hybrid prediction model of recycled sodium aluminate solution concentration in evaporation process. *IEEE Transactions on Instrumentation and Measurement*[J], 2021, 70: 1-13.
- [8] WANG W, YU W, ZHAO L J, et al. PCA and neural networks-based soft sensing strategy with application in sodium aluminate solution[J]. *Journal of Experimental & Theoretical Artificial Intelligence*, 2011, 23(1): 127-136.
- [9] WANG W, CHAI T Y, YU W, et al. Modeling component concentrations of sodium aluminate solution via hammerstein recurrent neural networks[J]. *IEEE Transactions on Control Systems Technology*, 2011, 20(4): 971-982.
- [10] GODDU R F, HUME D N. Photometric titrations[J]. *Analytical Chemistry*, 1954, 26(11): 1740-1746.
- [11] WATLING H. Spectroscopy of concentrated sodium aluminate solutions[J]. *Applied Spectroscopy*, 1998, 52(2): 250-258.
- [12] HADARUGA N G, HADARUGA D I, ISENGARD H D. Water content of natural cyclodextrins and their essential oil complexes: A comparative study between Karl Fischer titration and thermal methods[J]. *Food Chemistry*, 2012, 132(4): 1741-1748.
- [13] DASH B, TRIPATHY B C, BHATTACHARYA I N, et al. Effect of temperature and alumina/caustic ratio on precipitation of boehmite in synthetic sodium aluminate liquor[J]. *Hydrometallurgy*, 2007, 88(1-4): 121-126.

- [14] BROWNE G R, FINN C W P. The effects of aluminum content, temperature and impurities on the electrical conductivity of synthetic bayer liquors[J]. Metallurgical Transactions B, 1981, 12: 487-492.
- [15] BARRON J J, ASHTON C. The effect of temperature on conductivity measurement[J]. TSP, 2005, 7(3): 1-5.
- [16] 高慷婷, 柴天佑. 端边云协同的氧化铝生产过程苛性碱浓度智能预报方法[J]. 自动化学报, 2022, 45(x): 1-10.
- GAO S T, CHAI T Y. Intelligent forecasting method of caustic concentration in alumina production process based on end-edge-cloud coordination[J]. Acta Automatica Sinica, 2022, 45(x): 1-10.
- [17] CHAI T Y, ZHANG J W, YANG T. Demand forecasting of the fused magnesia smelting process with system identification and deep learning[J]. IEEE Transactions on Industrial Informatics, 2021, 17(12): 8387-8396.
- [18] LI Y R, ZHU Z F, KONG D Q, et al. EA-LSTM: evolutionary attention-based LSTM for time series prediction[J]. Knowledge-Based Systems, 2019, 181: 104785.
- [19] XIE Y, LIANG R L, LIANG Z L, et al. Speech emotion classification using attention-based LSTM[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2019, 27(11): 1675-1685.
- [20] SRIVASTAVA N, HINTON G, KRIZHEVSKY A, et al. Dropout: a simple way to prevent neural networks from overfitting[J]. The Journal of Machine Learning Research, 2014, 15(1): 1929-1958.
- [21] BA L J, FREY B. Adaptive dropout for training deep neural networks[J]. Advances in Neural Information Processing Systems, 2013, 26: 3084-3092.
- [22] HAN Y M, QI W, DING N, et al. Short-time wavelet entropy integrating improved LSTM for fault diagnosis of modular multilevel converter[J]. IEEE Transactions on Cybernetics, 2021, 52(8): 7504-7512.
- [23] ZHEN H, NIU D X, WANG K K, et al. Photovoltaic power forecasting based on GA improved Bi-LSTM in microgrid without meteorological information[J]. Energy, 2021, 231: 120908.
- [24] JIAO F, HUANG L, SONG R, et al. An improved STL-LSTM model for daily bus passenger flow prediction during the COVID-19 pandemic[J]. Sensors, 2021, 21(17): 5950.
- [25] ASWATHY A L, HAREENDRAN A, SS V C. COVID-19 diagnosis and severity detection from CT-images using transfer learning and back propagation neural network[J]. Journal of Infection and Public Health, 2021, 14(10): 1435-1445.
- [26] CHAI T F, DRAXLER R R. Root mean square error (RMSE) or mean absolute error (MAE)?-Arguments against avoiding RMSE in the literature[J]. Geoscientific Model Development, 2014, 7(3): 1247-1250.